Modélisation probabiliste et simulation Monte Carlo du risque en assurance automobile

Alfred Djogbessi
Projet personnel de modélisation du risque
Licence 3 Mathématiques
Université Le Havre Normandie

Résumé

La gestion du risque constitue un enjeu central pour les compagnies d'assurance. Dans ce projet, nous proposons une modélisation probabiliste simple du risque en assurance automobile à partir d'un modèle fréquence-sévérité. Le nombre de sinistres est modélisé par une loi de Poisson, tandis que le coût des sinistres suit une loi log-normale. Une simulation de Monte Carlo est ensuite utilisée afin d'estimer la distribution des pertes annuelles d'un portefeuille d'assurance.

L'étude permet notamment d'évaluer la perte moyenne, la variabilité des pertes ainsi qu'un quantile de risque de type Value at Risk à 95%. Elle illustre ainsi le rôle des probabilités, de la statistique et de la simulation dans l'évaluation quantitative du risque.

Table des matières

0.1 Introduction 2
0.2 Cadre théorique 2
0.2.1 Modèle de risque agrégé 2
0.2.2 Modélisation de la fréquence 2
0.2.3 Modélisation de la sévérité 3
0.3 Méthodologie de simulation 3
0.4 Implémentation sous R 3
0.5 Résultats de la simulation 4
0.5.1 Statistiques descriptives 4
0.5.2 Distribution des pertes 5
0.5.3 Analyse graphique 6
0.5.4 Mesure du risque : Value at Risk 8
0.5.5 Convergence de la simulation Monte Carlo 9
0.6 Discussion 10
0.7 Conclusion 11
0.8 Références 12
0.9 Annexe : Code R 13

0.1 Introduction

L'assurance repose sur la capacité à anticiper des événements incertains et à en évaluer les conséquences financières. Dans le domaine de l'assurance automobile, les compagnies doivent estimer le montant total des sinistres susceptibles de survenir sur une période donnée afin de déterminer les primes d'assurance, constituer des provisions et gérer leur exposition au risque.

La modélisation probabiliste constitue un outil essentiel pour représenter ces phénomènes aléatoires. Une approche classique en actuariat consiste à séparer deux composantes fondamentales du risque :

— la **fréquence des sinistres**, correspondant au nombre d'accidents sur une période donnée,

— la **sévérité des sinistres**, correspondant au coût associé à chaque accident.

Cette décomposition permet de construire un modèle de risque agrégé décrivant la perte totale d'un portefeuille d'assurance.

L'objectif de ce travail est d'étudier un modèle probabiliste simple du risque en assurance automobile et d'estimer la distribution des pertes annuelles à l'aide de la méthode de simulation Monte Carlo.

0.2 Cadre théorique

0.2.1 Modèle de risque agrégé

La perte totale annuelle d'un portefeuille d'assurance est modélisée par :

$$S = \sum_{i=1}^{N} X_i$$

où :

— N représente le nombre de sinistres sur une année,

— X_i représente le coût du i-ème sinistre,

— S représente la perte totale annuelle.

Ce modèle est appelé modèle de risque agrégé. Il permet de représenter la perte totale d'un portefeuille d'assurance comme la somme des coûts individuels de sinistres sur une période donnée.

0.2.2 Modélisation de la fréquence

Le nombre de sinistres est supposé suivre une loi de Poisson :

$$N \sim \mathcal{P}(\lambda)$$

où λ représente le nombre moyen de sinistres par an.

La loi de Poisson est couramment utilisée pour modéliser le nombre d'événements rares et indépendants se produisant sur une période donnée. Dans le contexte de l'assurance automobile, elle constitue une approximation simple et fréquemment utilisée pour représenter la fréquence des accidents.

0.2.3 Modélisation de la sévérité

Le coût d'un sinistre est supposé suivre une loi log-normale :

$$X_i \sim \text{Lognormale}(\mu, \sigma^2)$$

Cette distribution est adaptée à la modélisation des pertes financières car elle permet de représenter des variables strictement positives ainsi qu'une asymétrie vers les grandes valeurs. Dans les données d'assurance, il est fréquent d'observer de nombreux sinistres de faible montant et, plus rarement, des sinistres très coûteux.

0.3 Méthodologie de simulation

Afin d'estimer la distribution de la perte annuelle S, nous utilisons une simulation de Monte Carlo.

La procédure est la suivante :

1. Simuler le nombre de sinistres N selon une loi de Poisson.
2. Simuler les coûts des sinistres selon une loi log-normale.
3. Calculer la perte annuelle totale S.
4. Répéter cette procédure sur un grand nombre de simulations.

Dans cette étude, nous effectuons **10 000 simulations**.

0.4 Implémentation sous R

La simulation du modèle de risque est réalisée à l'aide du langage statistique **R**. L'objectif est de générer un grand nombre de pertes annuelles simulées afin d'approcher la distribution de la variable aléatoire S.

Pour chaque simulation :

— le nombre de sinistres N est généré selon une loi de Poisson à l'aide de la fonction `rpois()`,

— les coûts individuels des sinistres sont générés selon une loi log-normale avec la fonction `rlnorm()`,
— la perte totale annuelle est obtenue en sommant les coûts simulés.

Cette procédure est répétée 10 000 fois afin d'obtenir un échantillon de pertes annuelles simulées.

Les fonctions `mean()`, `sd()` et `quantile()` sont ensuite utilisées pour calculer les principales statistiques descriptives de la distribution des pertes.

0.5 Résultats de la simulation

Nous considérons un portefeuille d'assurance caractérisé par :
— $\lambda = 20$ sinistres en moyenne par an,
— une distribution log-normale pour les coûts.

0.5.1 Statistiques descriptives

Les résultats obtenus sont présentés dans le tableau suivant.

Indicateur	Valeur estimée
Perte moyenne	36 341
Écart-type	13 451
Médiane	34 753
Quantile 95% (VaR)	60 291

TABLE 1 – Statistiques descriptives des pertes simulées

Les résultats de la simulation montrent que la perte annuelle moyenne du portefeuille est d'environ 36 341 unités monétaires. La médiane est légèrement inférieure, ce qui reflète une distribution asymétrique vers les grandes pertes.

L'écart-type estimé à 13 451 indique une variabilité importante du montant total des sinistres.

Le quantile à 95% de la distribution, correspondant à une Value at Risk (VaR) à 95%, est d'environ 60 291. Cela signifie que dans 95% des scénarios simulés, la perte annuelle reste inférieure à ce niveau.

0.5.2 Distribution des pertes

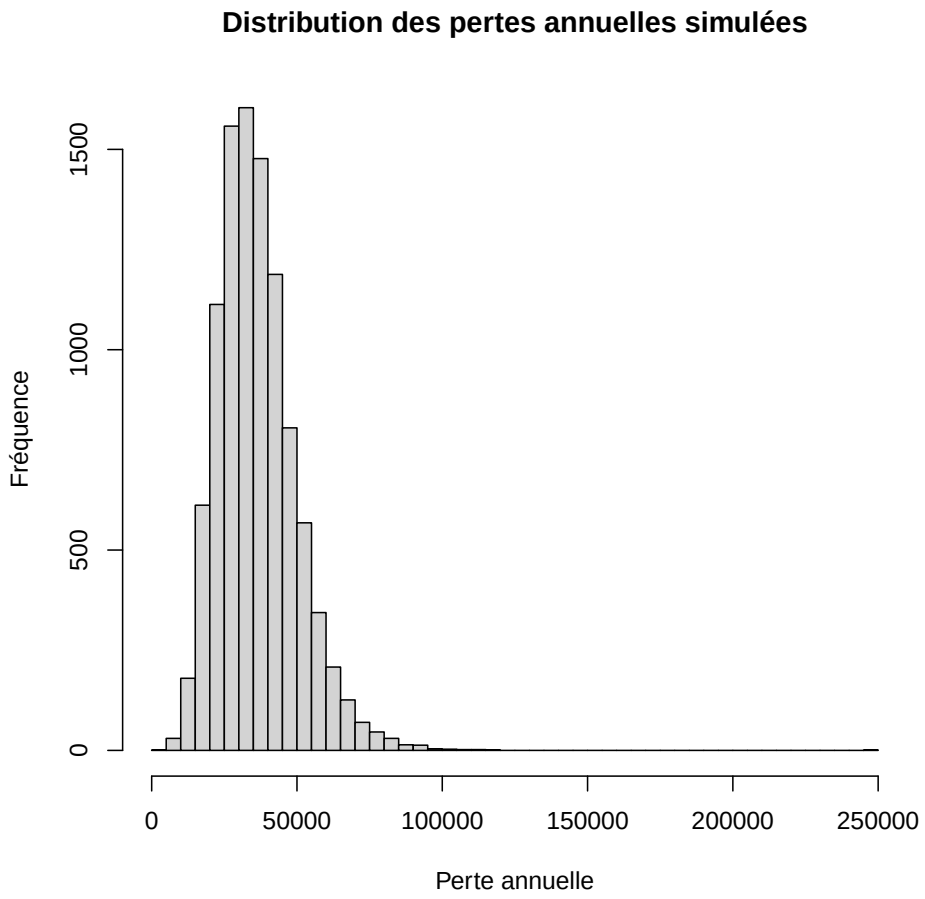

FIGURE 1 – Histogramme des pertes annuelles simulées pour un portefeuille d'assurance automobile

La figure présente l'histogramme des pertes annuelles obtenues par simulation Monte Carlo. Chaque observation correspond à la perte totale simulée pour une année d'activité du portefeuille d'assurance.

La distribution observée est clairement asymétrique vers la droite, ce qui signifie que les pertes élevées sont possibles mais relativement rares. Cette asymétrie est principalement due à la distribution log-normale utilisée pour modéliser le coût des sinistres.

Dans la majorité des simulations, la perte annuelle se situe autour de la moyenne estimée, mais certaines simulations produisent des pertes significativement plus importantes. Ce phénomène est caractéristique des modèles de risque en assurance, où des événements peu fréquents peuvent entraîner des coûts élevés.

0.5.3 Analyse graphique

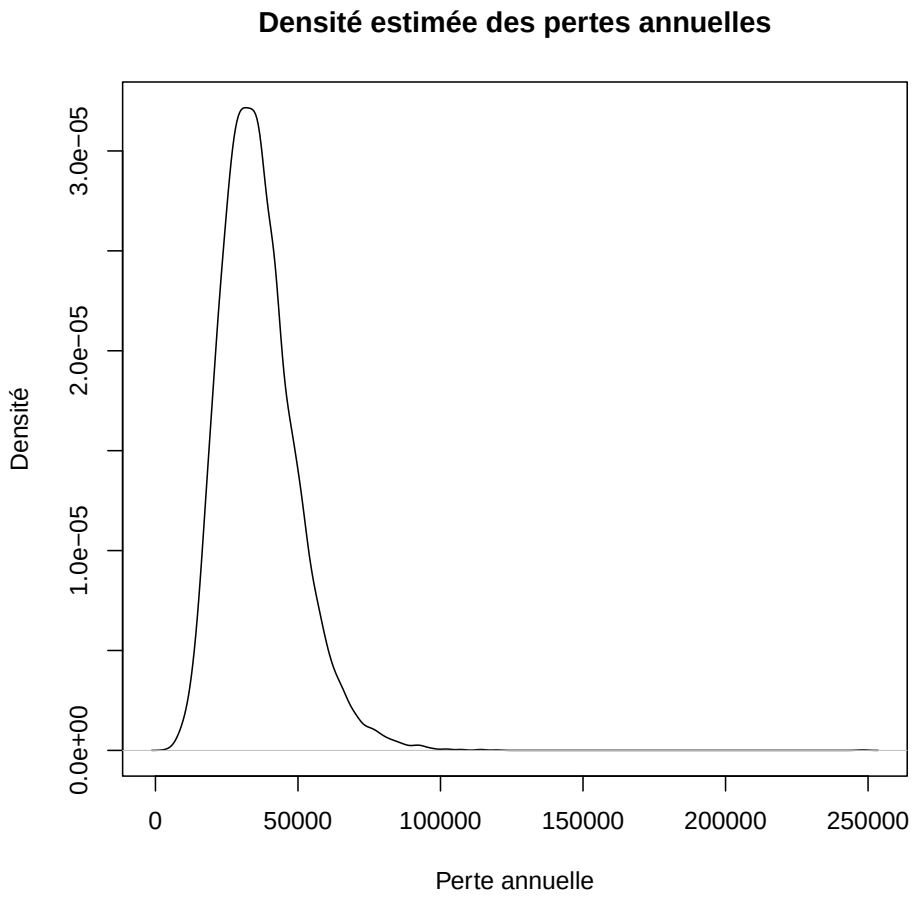

FIGURE 2 – Densité empirique des pertes annuelles simulées

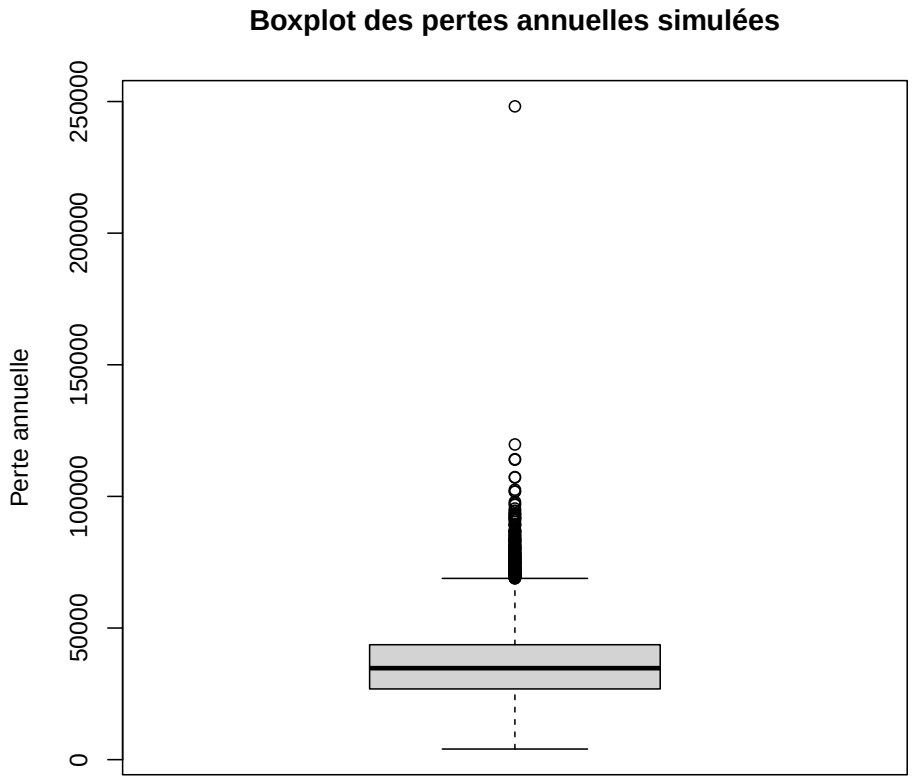

FIGURE 3 – Boxplot des pertes simulées

La figure représentant la densité empirique des pertes permet d'obtenir une estimation lissée de la distribution des pertes annuelles simulées. On observe une concentration importante des valeurs autour d'une zone centrale proche de la moyenne estimée.

Le boxplot des pertes simulées met en évidence la médiane, la dispersion des données ainsi que la présence de valeurs extrêmes. Ces observations confirment que la distribution des pertes présente une asymétrie vers les grandes valeurs.

Dans le contexte de l'assurance, ces valeurs extrêmes correspondent à des scénarios de sinistres particulièrement coûteux. Même si ces événements sont peu fréquents, ils jouent un rôle important dans l'évaluation du risque global du portefeuille.

0.5.4 Mesure du risque : Value at Risk

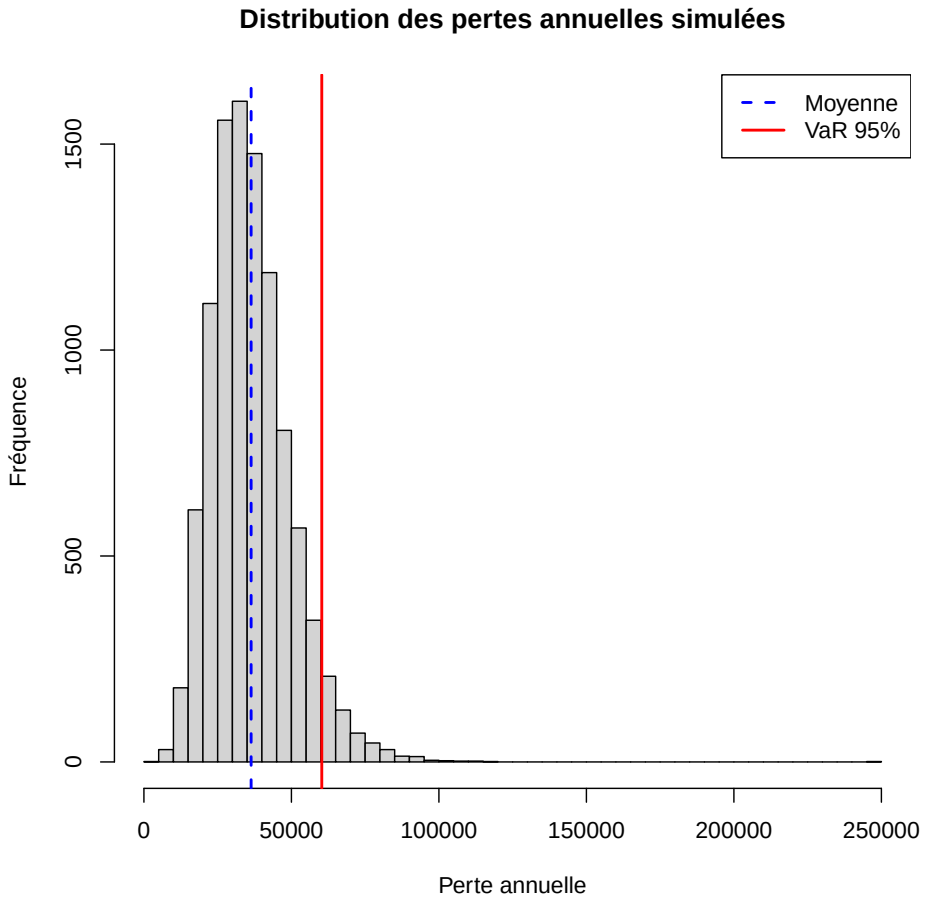

FIGURE 4 – Distribution des pertes annuelles simulées avec moyenne et VaR à 95%.

La figure suivante présente l'histogramme des pertes annuelles simulées, ainsi que deux indicateurs importants : la perte moyenne et la Value at Risk (VaR) à 95%.

La ligne correspondant à la moyenne indique le niveau de perte attendu pour le portefeuille d'assurance sur une année. Elle représente donc le coût moyen que l'assureur peut anticiper à long terme.

La ligne représentant la VaR à 95% correspond à un seuil de perte élevé mais plausible. Plus précisément, elle indique que dans 95% des scénarios simulés, la perte annuelle reste inférieure à ce niveau. Seuls 5% des scénarios produisent des pertes supérieures à ce seuil.

Cette mesure est particulièrement importante en gestion du risque car elle permet d'évaluer l'exposition du portefeuille à des événements défavorables mais relativement rares.

0.5.5 Convergence de la simulation Monte Carlo

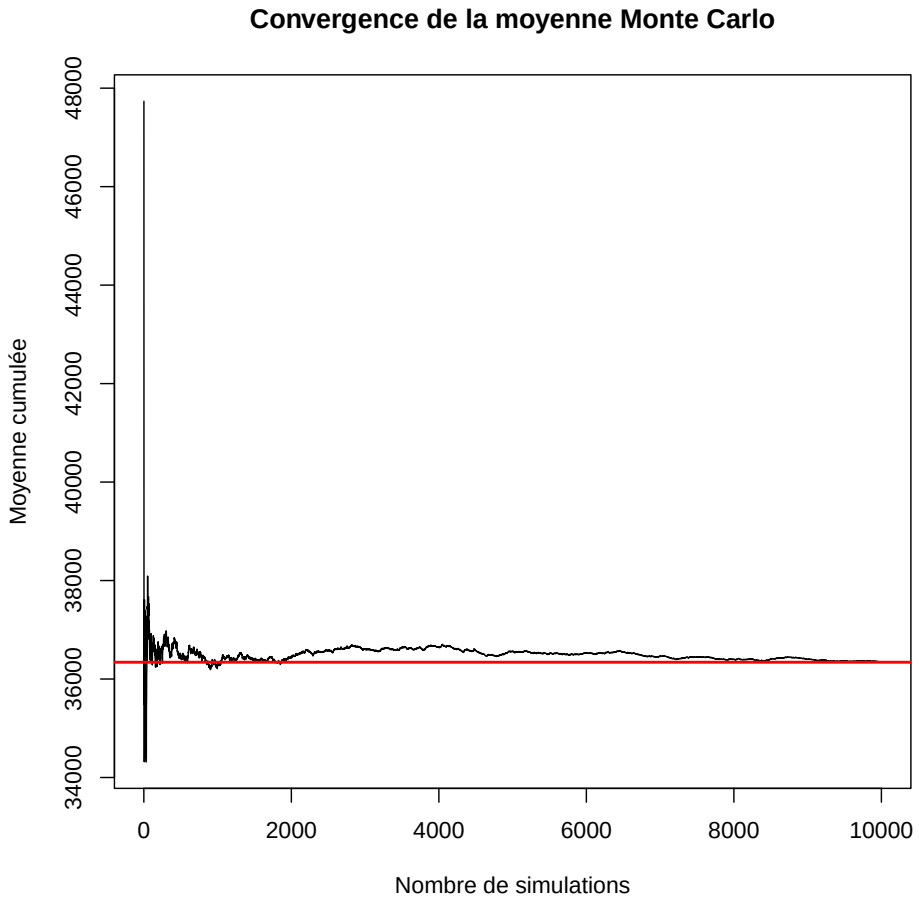

FIGURE 5 – Convergence de la moyenne estimée des pertes par simulation Monte Carlo.

La figure suivante illustre la convergence de la moyenne estimée des pertes lorsque le nombre de simulations augmente. Chaque point du graphique correspond à la moyenne cumulée des pertes simulées après un certain nombre de simulations.

On observe que la moyenne estimée fluctue fortement au début de la simulation, lorsque le nombre d'observations est faible. Cependant, à mesure que le nombre de simulations augmente, la moyenne se stabilise progressivement autour d'une valeur proche de la moyenne finale estimée.

Ce phénomène illustre la convergence de la simulation Monte Carlo et confirme que le nombre de simulations utilisées dans cette étude est suffisant pour obtenir une estimation stable de la perte moyenne.

0.6 Discussion

Le modèle présenté dans ce projet constitue une représentation simplifiée du risque en assurance automobile. Il repose sur un modèle fréquence-sévérité dans lequel le nombre de sinistres est modélisé par une loi de Poisson et le coût des sinistres par une loi log-normale.

Bien que ce cadre soit largement utilisé en actuariat pour l'analyse des pertes, il repose sur plusieurs hypothèses simplificatrices.

Tout d'abord, le modèle suppose que les sinistres sont indépendants les uns des autres et que leur distribution reste identique au cours du temps. Dans la réalité, les sinistres peuvent être influencés par de nombreux facteurs tels que le profil des conducteurs, les conditions météorologiques ou encore les évolutions réglementaires.

Par ailleurs, la loi de Poisson utilisée pour modéliser la fréquence des sinistres suppose que la variance est égale à la moyenne. Or, dans les données réelles d'assurance, il est fréquent d'observer une variabilité plus importante, ce qui peut nécessiter l'utilisation de modèles alternatifs.

De même, la distribution log-normale utilisée pour modéliser la sévérité des sinistres constitue une approximation simple. D'autres distributions de pertes peuvent être utilisées afin de mieux représenter la queue de distribution des sinistres importants.

Enfin, les paramètres du modèle ont été choisis à titre illustratif et ne proviennent pas de données empiriques réelles. Dans un contexte actuariel réel, ces paramètres seraient estimés à partir de données historiques.

Malgré ces simplifications, le modèle étudié permet d'illustrer les principes fondamentaux de la modélisation du risque et l'intérêt des simulations Monte Carlo pour analyser la distribution des pertes d'un portefeuille d'assurance.

0.7 Conclusion

Dans ce projet, nous avons étudié un modèle probabiliste simple du risque en assurance automobile à partir d'un modèle fréquence-sévérité. Le nombre de sinistres a été modélisé par une loi de Poisson, tandis que le coût des sinistres a été représenté par une loi log-normale.

La simulation Monte Carlo a permis de générer un grand nombre de pertes annuelles simulées et d'analyser leur distribution. Les résultats obtenus ont permis d'estimer plusieurs indicateurs importants, notamment la perte moyenne annuelle, la variabilité des pertes ainsi qu'un quantile de risque de type Value at Risk à 95%.

L'analyse graphique de la distribution des pertes met en évidence une asymétrie vers les grandes valeurs, ce qui reflète la possibilité de pertes importantes mais relativement rares. La convergence de la moyenne simulée confirme par ailleurs la stabilité de la méthode de simulation utilisée.

Ce travail illustre l'intérêt des méthodes probabilistes et des simulations Monte Carlo pour l'analyse du risque en assurance. Dans un contexte réel, ce type de modèle pourrait être enrichi par l'utilisation de données empiriques et par l'étude de modèles de fréquence et de sévérité plus élaborés.

0.8 Références

— Klugman, S. A., Panjer, H. H., & Willmot, G. E. (2012). *Loss Models : From Data to Decisions*. Wiley.

— Charpentier, A., & Gallic, E. (2016). *Actuariat avec R*. Economica.

0.9 Annexe : Code R

Le code suivant présente l'implémentation utilisée pour simuler la distribution des pertes annuelles dans le modèle fréquence-sévérité. Les simulations sont réalisées à l'aide du langage R et reposent sur la génération d'un nombre de sinistres selon une loi de Poisson et de coûts de sinistres selon une loi log-normale.

```
lambda <- 20
mu <- 7
sigma <- 1
n_sim <- 10000

losses <- numeric(n_sim)

for (j in 1:n_sim){
  N <- rpois(1, lambda)
  costs <- rlnorm(N, mu, sigma)
  losses[j] <- sum(costs)
}

mean(losses)
sd(losses)
quantile(losses,0.95)
```